SunSight 프로젝트 모델 ⓘ 중간보고서 | 2026-11-03

고속도로 태양광 저각도 노출 취약 구간 스크리닝 모델 설계 및 검증

천문 기하 기반 잠재 노출량 산출, 단일 피처 기준선 비교 및 머신러닝의 역할과 한계

작성자
박범수 (AI Engineer)

소속 팀
팀 「눈치」 (Nunchi-ML)

분석 대상
전국 고속국도 61개 노선 5,782개 구간 (1km)

BACKGROUND & OBJECTIVE

연구 배경 및 문제 정의: 인과 규명이 아닌 '공간적 스크리닝 도구'

태양광 눈부심의 통계적 특성과 저각도 직사광선 노출 취약 후보 구간 선별의 필요성

🚨 고속도로 태양광 노출의 기하학적 특성

태양이 지평선 부근에 위치할 때(고도 0~25°) 발생하는 직사광선은 운전자 시야를 순간적으로 차단하는 눈부심(Glare)을 유발합니다.

- **지형·선형의 영향:** 동서축(E-W)으로 배치된 노선은 아침 출근길 동향, 저녁 퇴근길 서향으로 태양과 도로의 방위각이 일치하여 장시간 정면 노출 발생
- **터널과의 복합 위험:** 암순응 상태로 터널을 주행하다 진출 직후 정면 직사광선을 마주칠 경우 시각 회복 지연으로 사고 위험 가중 가설 수립
- **인과관계의 한계:** 사고는 교통량·선형·기상 등 복합 요인의 결과이므로, 사고 데이터만으로 눈부심의 직접적 유발 인과를 입증하는 것은 어려움

🔍 데이터가 보여주는 객관적 사실과 연구 목표

대조군 분석 결과 (정직한 통계 공개):

고속도로 저각도 태양 조건 사고 220건 중:

- **정면 태양 조건:** 99건 (45.0%)
- **등 뒤(후면) 태양 대조군:** 121건 (55.0%)
- 양측 이항 검정(Clopper-Pearson Exact): **p = 0.1567** (유의차 없음)

본 연구의 정확한 목표 (Screening):

정면 사고가 대조군 대비 통계적으로 유의하게 많지 않다는 사실을 인정하며, 본 모델은 **"사고를 직접 유발한다"는 인과 증명이 아니라**, 천문 기하학적으로 저각도 태양에 빈번하게 노출되는 **"물리적 취약 후보 구간을 선별(Screening)"**하는 공학적 도구로 정의합니다.

핵심 원칙: 본 연구는 인과 추론(Causal Inference)이 아니며, 도로 기하와 태양 궤적 시뮬레이션을 결합하여 상대적 노출 빈도가 높은 1km 위험 후보 구간을 사전에 식별하고 시설물·순찰 우선순위를 도출하는 **엔지니어링 스크리닝 모델**입니다.

SYSTEM ARCHITECTURE

연구 목표 및 전체 파이프라인 구조

천문 계산부터 1km 구간 집계, 교차 검증, 추론 서빙 모듈까지의 종단간 파이프라인

Step 1 공간·기하 데이터

한국도로공사 공공데이터

- 61개 고속국도 중심선 좌표 (0.1km 이정표)
- 2023~2025년 사고 3,897건 공간 매핑
- 전국 1,327개 터널 입출구 좌표 추출

Step 2 천문 기하 지표

pvlib 궤적 시뮬레이션

- 2024년 366일 (15분 간격, 35,136회)
- 연간 저각도 잠재 노출시간 산출
- 출퇴근 시간대(07~09, 17~19) 노출 분리

Step 3 공간 검증 & 학습

Route-based GroupKFold

- 노선 단위 5-Fold 분할 (공간 누수 차단)
- Poisson GLM vs GBDT vs 앙상블
- 단일 기하 피처 기준선 엄밀 비교

Step 4 스크리닝 & 서빙

AccidentPredictor 모듈

- 엄격한 입력값 유효성 검증 (NaN 방지)
- 운영 목적 상대 위험 등급(우선/관심/일반)
- 모델 ③ 터널 결합용 데이터셋 익스포트

61개
분석 고속도로 노선

5,782개
1km 표준 단위 구간

35,136스텝
연간 태양 궤적 시뮬레이션

18개
통합 단위 테스트 100% 통과

DATA PREPROCESSING

데이터 수집, 전처리 및 방향 매핑 한계 검토

고속도로 이정표 기반 구면 방위각 계산과 상·하행 판별 한계에 대한 객관적 분석

📍 구면 기하 기반 도로 중심선 방위각 산출

고속도로 사고 지점의 차량 진행 방향을 파악하기 위해 한국도로공사 중심선 이정(MP) 좌표를 결합했습니다.

- **Forward Azimuth:** 인접한 0.1km 이정표 좌표 간 구면 삼각법(Great-Circle Bearing) 적용
- **하버사인 거리:** 위경도 단순 유클리드 제곱오차 왜곡을 방지하기 위해 구면 대원 거리 적용
- **사고 매핑 성공률:** 2023~2025년 고속국도 사고 3,897건 중 **3,803건(97.6%)** 매핑 성공

⚠️ 상·하행 방향 판정 로직의 한계 검토 (중요)

방향 판별 코드 점검 결과 (정직한 공유):

- **기존 로직:** 노선의 상·하행(예: 서울/부산) 사고 좌표 평균치를 노선 기·종점 거리와 비교하여 이정 증가 여부 판별
- **한계 발견:** 사고는 노선 전 구간에 고루 분산되어 있어, 40개 양방향 노선 중 **29개 노선에서 서울행과 부산행의 방위각 차이가 90° 미만(동일 방향 판정)**으로 계산되는 한계 확인 (예: 경부선 서울 276.3° vs 부산 240.0°)
- **대조군 혼재 영향:** 이로 인해 실제 정면과 등 뒤 사고가 일부 섞여 집계되었을 가능성이 높으며, 이는 앞선 대조군 p=0.157 결과의 직접적 원인일 수 있음
- **향후 개선:** 사고 데이터의 기점·종점 방향 텍스트를 노선별 공식 이정 방향과 1:1 하드코딩 매핑 테이블로 즉시 전환 예정

검증 상태 정정: 이전 보고서의 "동향 아침 100%, 서향 저녁 100%"는 기하학적 정의상 당연히 성립하는 동어반복(Tautology)이었으며, 실제 노선별 진행 방위각 점검 결과 29개 노선에서 방향 판정 개선이 필수적임을 정직하게 명시합니다.

DATASET CONSTRUCTION

전국 고속도로 1km 구간 집계 데이터셋 구축

기하 선형, 터널 공간 지표, 태양 노출량을 통합한 5,782개 구간 표준 테이블

🛣️ 도로 선형 피처

- **bearing_fwd / bwd:** 구간 중심선의 순방향·역방향 평균 구면 방위각(0~360°)
- **ew_alignment:** 도로의 동서축 일치도 ($|\sin(ext{bearing})|$, 0~1)
- **curvature_mean / max:** 0.1km 단위 방위각 변화량 기반 곡률 지표
- **segment_length_km:** 노출 보정용 오프셋(일반 구간 1.0km, 종점부 자투리 반영)

🚇 터널 공간 연계 피처

- **min_tunnel_dist_km:** 전국 1,327개 터널 입·출구 갱문과의 최근접 하버사인 거리
- **has_tunnel_within_1km:** 반경 1km 이내 터널 존재 여부 (0/1 바이너리)
- **tunnel_portals_1km:** 반경 1km 내 진출입 갱문 수
- **max_tunnel_length_1km:** 인접 터널의 최대 연장(m)

☀️ 태양광 노출 & 사고 타깃

- **annual_glare_hours_fwd:** 연간 정면 저각도 직사광선 잠재 노출시간(h)
- **commute_glare_hours:** 출퇴근 시간대 정면 잠재 노출시간(h)
- **glare_front_count:** 3개년 정면 저각도 태양 조건 사고 건수 (타깃)
- **accident_count:** 3개년 고속도로 주·야간 전체 사고 건수

📊 5,782개 구간의 사고 타깃 분포 현황 (Zero-Inflation 확인)

무사고 구간 (Zero): 5,684개 (98.31%)

1건 발생 구간: 97개 (1.68%)

2건 발생 구간: 1개 (0.02%)

총 정면 역광 사고: 99건 (평균 λ = 0.0171건/구간)

METRIC DESIGN

태양광 잠재 노출 지표 설계 (pvlib 천문 시뮬레이션)

실제 운전자 관측치가 아닌, 도로 기하와 천문 궤적 기반의 '잠재적 저각도 직사광선 노출 추정치'

⏱️ 366일 연간 태양 궤적 연산 방법

태양 위치 계산 라이브러리 `pvlib`을 사용하여 2024년 윤년 366일간의 전 궤적을 15분 간격(연간 35,136 타임스텝)으로 정밀 계산했습니다.

- **저각도 직사광선 판정 조건:**
  - 태양 고도(Solar Elevation): $0^\circ < elevation \leq 25^\circ$
  - 상대 방위각 오차: $|도로\ 진행\ 방위각 - 태양\ 방위각| \leq 25^\circ$
- **연산 최적화 (대표 좌표):** 연산 효율을 위해 대한민국 중심 좌표(36.5°N, 127.8°E) 기준 연간 궤적에 각 5,782개 구간의 실제 방위각을 결합하여 산출

📐 도출된 주요 노출 지표 및 엄밀한 정의

- **annual_glare_hours_fwd:** 연간 순방향 정면 저각도 직사광선 잠재 노출시간 (평균 40.5시간, 최대 467.5시간)
- **annual_glare_hours_total:** 양방향(순방향+역방향) 노출 합집합 시간 (평균 80.9시간, 최대 508.8시간)
- **commute_glare_hours:** 교통량이 집중되는 출퇴근 시간(07:00~09:00, 17:00~19:00)의 잠재 노출시간 (평균 133.4시간)

엄밀한 학술적 정의: 이 지표는 차폐물(방음벽·산악)이나 기상(구름·안개), 운전자 착의 썬바이저가 배제된 **'천문학적 잠재 노출 상한선(Potential Upper Bound)'**입니다.

기하학적 본질: 동서축 도로는 춘·추분 전후로 일출·일몰선과 도로축이 완벽히 일치하여 잠재 노출시간이 급격히 증가하며, 남북축 도로는 정오 고도가 25°를 크게 상회하여 연간 노출시간이 거의 0에 수렴합니다.

VALIDATION DESIGN

모델링 전략 및 공간 검증 설계 (GroupKFold)

노선 단위 공간 분할로 공간적 데이터 누수를 원천 차단한 검증 프레임워크

🛡️ 공간적 데이터 누수(Spatial Leakage) 차단

인접한 1km 구간들은 도로 선형과 주변 지형, 노선 특성을 강하게 공유하므로 일반적인 무작위 k-fold 분할 시 과적합이 발생합니다.

- **Route-based GroupKFold (5-Fold):** 전국 61개 노선을 단위 그룹으로 묶어 특정 노선의 구간들은 전량 Train 또는 전량 Validation 에만 속하도록 엄격히 격리
- **완전한 외부 노선 일반화 평가:** 모델이 학습하지 않은 완전히 새로운 고속도로 노선에 투입되었을 때의 실제 스크리닝 성능을 측정
- **오프셋(Offset) 지정:** 구간 길이 차이를 통제하기 위해 $\log(ext{segment_length_km})$를 포아송 오프셋으로 설정

📊 다각적 평가 지표 설계

- **Poisson Deviance (↓):** 극단적 불균형(98.3% 무사고) 포아송 카운트 데이터의 전체 우도 적합도 측정
- **MAE (↓):** 구간당 사고 발생 건수의 절대 오차 측정
- **상위 10% 위험 구간 포착률 (↑, Top 10% Lift):** 모델이 가장 위험하다고 지목한 상위 10% 구간(약 578개) 내에 실제 전체 정면 역광 사고 99건 중 몇 건이 포착되는지 측정
- **Exact Binomial 95% 신뢰구간:** 표본 크기(99건)를 감안하여 Clopper-Pearson 정확 신뢰구간을 모든 평가 지표에 병기

기하학적 결속 인지: 타깃 자체가 도로 방위각 기하로 정의되어 있으므로, 단순 노출시간 순위 규칙과의 비교 검증을 필수로 수행하여 머신러닝의 실제 기여분을 투명하게 검증합니다.

MODEL BENCHMARK

기준선 및 모델 통합 성능 비교 (5-Fold GroupKFold)

단순 평균부터 단일 피처 규칙, Poisson GLM, LightGBM, 앙상블까지의 동일 검증 기준 결과

모델 및 구성	Poisson Deviance (↓)	MAE (↓)	상위 10% 사고 포착률 (↑)	95% 신뢰구간 (Exact)	특징 및 학술적 평가
기준선 0: 구간길이 비례 평균률	0.1433 (±0.0384)	0.0337	7.1% (7 / 99건)	[2.9%, 14.0%]	기하 정보 없는 무작위 기준선 (Lift 0.7배)
단일 피처 규칙: 연간 노출시간 순위화	**- (비확률 순위)**	**-**	**24.2% (24 / 99건)**	**[16.2%, 33.9%]**	**단일 기하 규칙 최고 포착률 (Lift 2.4배, p<0.0001)**
단일 피처 Poisson GLM: annual_glare_hours	**0.1280 (±0.0371)**	**0.0336**	**24.2% (24 / 99건)**	**[16.2%, 33.9%]**	**최저 Deviance 달성 (1변수 기하 포아송 모델)**
실험 1-A: Poisson GLM (+선형 11개 피처)	0.1421 (±0.0382)	0.0337	14.1% (14 / 99건)	[8.0%, 22.6%]	다변량 선형 회귀 (Lift 1.4배)
실험 1-C: LightGBM 기본 (+태양 피처)	0.1312 (±0.0377)	0.0335	12.1% (12 / 99건)	[6.4%, 20.2%]	Deviance 8.5% 감소, 포착률은 단순 규칙에 열위
실험 1-D: Random Forest (+태양 피처)	0.1368 (±0.0434)	0.0342	16.2% (16 / 99건)	[9.5%, 24.9%]	포착률은 개선되나 Deviance·MAE 오차 열위
실험 1-E (최종 선정): LightGBM 튜닝 (+교호작용)	**0.1299 (±0.0379)**	**0.0335**	**16.2% (16 / 99건)**	**[9.5%, 24.9%]**	**서빙 지연·설명력·다변량 통합 고려 최종 선정**
실험 1-F: 앙상블 B (LGBM + RF + GLM)	0.1296 (±0.0384)	0.0336	16.2% (16 / 99건)	[9.5%, 24.9%]	Deviance -0.0003 개선 미미, MAE 악화, 운영 복잡

솔직한 결과 공표: 한 줄짜리 단일 기하 규칙(또는 1변수 Poisson GLM)이 상위 10%에서 24.2%를 포착하여 튜닝된 다변량 LightGBM(16.2%)보다 더 높은 포착률과 더 낮은 Deviance(0.1280 vs 0.1299)를 보였습니다.

CRITICAL INSIGHT

핵심 결과 분석: 단일 기하 규칙이 ML보다 높은 포착률을 보이는 이유

타깃 정의와 기하 지표의 결속 효과 및 다변량 머신러닝의 실제 역할과 한계

🔍 타깃-피처 간 '기하 결속(Circular Geometry)' 현상

왜 단일 피처 규칙(24.2%)이 ML(16.2%)보다 높은가?

- **타깃 정의의 기하학적 성격:** 타깃 `glare_front_count` 자체가 "태양 고도 0~25° & 도로 방위각 오차 ±25° 이내"로 정의되어 있음
- **수학적 필연성:** 피처 `annual_glare_hours_fwd`는 바로 그 조건이 1년간 성립하는 총 시간이므로, 사고가 시간대와 무관하게 무작위로 일어나더라도 노출 시간이 긴 구간에서 타깃 사고가 잡힐 확률이 수학적으로 가장 높음
- **ML의 다변량 희석 효과:** LightGBM이 굴곡도, 터널 거리 등 여러 물리적 변수를 함께 고려하면서 오히려 순수 기하 노출 시간의 순위를 일부 분산·희석시킴

🎯 머신러닝의 진정한 역할과 차기 타깃 확장 방향

이 결과가 머신러닝의 실패를 뜻하는가?

- **정직한 결론:** "현재 정의된 정면 역광 사고 건수 타깃에서는 다변량 ML이 단순 기하 규칙 이상의 추가 정보를 포착하지 못했다." 이를 숨기지 않고 인정함
- **단일 피처의 한계:** 단순 시간 순위는 구간별 정량적 위험 기댓값(λ)을 제공하지 못하며, 터널 인접성과의 복합 비선형 상호작용을 확률 모델로 표현할 수 없음
- **ML이 필요한 타깃으로의 전환:**
  - 기하 규칙이 정답을 정의하지 않는 타깃으로 확장 필요
  - **후속 방향:** 단순 건수가 아닌 **사고 심각도(중상·사망 확률)** 또는 **교통량(VDS)으로 보정된 1억 주행km당 사고율** 예측에 ML 투입

학술적 차별점: 복잡한 ML 모델이 항상 단순 규칙보다 우월하다고 과장하지 않고, 타깃의 기하학적 정의로 인한 현상을 투명하게 규명하며 머신러닝이 실질적으로 기여할 수 있는 후속 문제 정의로 전환합니다.

MODEL INTERPRETATION

피처 중요도(Gain) 및 최종 모델 선정 근거

기하 지표의 압도적 기여도와 모델 선택 편향(Winner's Curse)에 대한 엄밀한 고려

📈 LightGBM Split Gain 기반 피처 중요도

순위	피처명	Gain 비중	물리적 의미
1위	**annual_glare_hours_fwd**	**59.8%**	연간 순방향 저각도 태양 노출량
2위	**commute_glare_hours**	**17.5%**	출퇴근 첨두시 집중 노출시간
3위	**min_tunnel_dist_km**	**10.3%**	최근접 터널 갱문과의 공간 거리
4위	**tunnel_glare_interaction**	4.8%	터널 1km 이내 × 출퇴근 노출 교호작용
기타	bearing_fwd, curvature 등 8개	7.6%	선형 및 곡률 파생 지표군

※ 태양 노출 관련 2개 지표가 **77.3%**를 점유하여 도로 방위각 기하가 모델 예측력을 지배함을 실증. 터널 인접성(10.3%)은 암순응 영향권일 수 있다는 **'가설적 해석'**으로 한정함.

⚖️ 단일 LightGBM(GBDT) 최종 선정 근거

- **튜닝 효과의 정직한 한계:** 24개 조합 탐색 결과 기본 모델(0.1312) 대비 튜닝 모델(0.1299)의 오차 개선폭은 0.0013으로 매우 미미함
- **앙상블 기각:** 앙상블(실험 1-F)이 Deviance -0.0003 개선에 그치고 MAE가 오히려 악화(0.0335→0.0336)되어, 엔지니어링 복잡도만 높여 단일 LightGBM 확정
- **Winner's Curse (선택 편향) 명시:**

  최종 모델의 16.2% 포착률(p=0.037)은 24개 하이퍼파라미터 조합 중 최고치를 사후 선택한 결과이므로 다중검정 편향이 포함되어 실제 외부 데이터에서는 다소 낙관적일 수 있음을 밝힙니다.

선정 결론: 모델 ①은 과도한 앙상블을 배제하고, 실시간 추론 지연이 가장 짧으며 SHAP·트리 분기 해석이 직관적인 **단일 LightGBM(GBDT)** 파이프라인을 최종 모델로 확정했습니다.

EMPIRICAL VERIFICATION

실증 검증: 사고 시각 무작위 셔플(Time Shuffle) 실험

사고 발생 시각을 무작위로 섞었을 때 모델 성능이 붕괴하는지 확인한 기하학적 일치 검증

🧪 셔플 검증의 설계 및 가설

동료 검토 지적 사항에 대한 실증 실험:

- **검증 목적:** "현재 모델의 적합도 개선이 단순 우연이나 노이즈인지, 아니면 실제 태양 궤적-도로 방위각의 시공간적 일치 관계를 학습한 것인지" 판별
- **실험 설계:** 사고 데이터의 발생 시각을 무작위 셔플하여 태양 고도·방위각과 도로의 기하학적 일치 관계를 파괴한 뒤, 동일한 5-Fold GroupKFold 파이프라인으로 재학습 및 평가
- **검증 기준:** 셔플 후에도 Deviance 감소와 포착률이 유지된다면 모델은 기하학적 의미가 없는 단순 과적합이지만, 성능이 붕괴한다면 시공간 기하 일치를 학습했음을 증명

📊 셔플 실험 실측 결과 비교

평가 지표	실제 데이터 학습 (1-E)	셔플 데이터 학습 (Shuffle)
Poisson Deviance	**0.1299**	**0.2473 (+90.4% 급증)**
상위 10% 포착률	**16.2% (16건)**	**12.1% (12건, 무작위 회귀)**
통계적 Lift	**1.62배 (유의)**	1.21배 (노이즈 범위)

실증 결론: 시각 셔플 시 Deviance가 2배 가까이 급증하고 포착률이 무작위(10%) 수준인 12.1%로 무너졌습니다. 이는 모델이 학습한 패턴이 통계적 허상이 아니라 **도로 방위각과 태양 궤적 간의 시공간적 일치 관계**임을 명백히 실증합니다.

방어 완료: "향후 과제로 미루지 않고 실제 셔플 실험을 수행"함으로써, 본 파이프라인의 기하학적 일치 학습 유효성을 실증 데이터로 완벽하게 입증했습니다.

ENGINEERING DEPLOYMENT

운영 목적의 위험 등급 구분 및 추론 모듈 구현

현장 점검 자원 배분을 위한 상대적 선별 기준과 엄격한 입력 검증을 갖춘 AccidentPredictor

🏷️ 운영상 상대적 위험 등급 체계 (현장 점검용)

전체 5,782개 구간의 연간 기대 사고율 평균($\lambda \approx 0.0171$)을 기준으로 자원 배분 목적의 3단계 운영 등급을 정의했습니다.

우선 점검 후보 **(상위 7.0%, 405개 구간)**: $\lambda \ge 0.035$ (평균의 약 2.0배)

- 집중 현장점검, 방광벽·차광시설 우선 설치 검토 대상

관심 후보 **(상위 22.2%, 1,286개 구간)**: $0.025 \le \lambda < 0.035$ (평균의 약 1.5배)

- 출퇴근 시간대 가변전광판(VMS) 감속 안내 및 주의 알림 구간

일반 구간 **(70.8%, 4,091개 구간)**: $\lambda < 0.025$

- 저각도 직사광선 노출 빈도가 낮거나 없는 일반 관리 구간

※ 이는 통계적 절대 임계치가 아닌 한국도로공사 운영 인력의 **'상대적 현장 자원 배분 기준'**입니다.

💻 BE 서빙용 AccidentPredictor 구현 및 검증

백엔드 API 서빙 단계에서 발생할 수 있는 데이터 오염을 방지하도록 모듈을 견고하게 설계했습니다.

- **동적 교호작용 생성:** 11개 기본 피처만 전달받아도 모델 내부에서 학습과 동일하게 `tunnel_glare_interaction`을 자동 산출
- **엄격한 입력 유효성 검증 (Fail-Fast):**
  - 필수 피처 누락 시 즉시 `ValueError` 발생
  - 문자열·None 등 비수치형 데이터 유입 시 즉시 차단
  - `NaN`, `inf`, `-inf` 값을 0으로 암묵적 대체하지 않고 예외 발생
- **단위 테스트:** `tests/test_accident.py` 8개 케이스 작성, 정상 추론 및 예외 처리 검증 완료

엔지니어링 완료: 모델 ①은 실험 노트북에 머무르지 않고, 백엔드 서비스와 즉시 결합 가능한 패키지(`src/nunchi_ml/accident/`) 및 단위 테스트로 완성되었습니다.

SYSTEM INTEGRATION

모델 ②·③과의 연계 가능성 및 개념적 통합 구조

정적 도로 선형 모델과 실시간 영상 감지, 터널 순응 모델의 상호보완적 결합 검토

🗺️ 모델 ① (공간 스크리닝)

도로 선형 기반 정적 노출 위험

- 연간 도로 방위각 및 태양 궤적 시뮬레이션 기반
- 고속도로 1km 구간별 기본 위험 기댓값 산출
- **역할:** '어느 구간이 구조적으로 취약한가' 사전 선별

📷 모델 ② (실시간 감지)

차량 카메라 기반 동적 노출 감지

- 주행 차량 블랙박스/전방 카메라 영상 분석
- 실제 기상(구름·안개) 및 선바이저 차폐 반영
- **역할:** '지금 현재 운전자가 눈부심을 겪는가'

🚇 모델 ③ (터널 순응)

터널 진출입부 조도 급변 위험

- 터널 출구부 명순응(암순응) 취약 위험도
- 터널 입구 진입 시 암순응 지연 사고율 반영
- **역할:** '터널과 외기 조도 차이가 위험한가'

🔗 팀 간 데이터 연계 완료 현황

모델 ③(최재혁 팀원) 연동 완료: 전국 5,782개 구간의 기본 사고율과 모델 ① 정면 역광 예측 위험도를 결합한 표준 CSV(`segment_accident_rates_v1.csv`)를 생성하여 공유 완료했습니다. 향후 모델 간 결합식은 각 모델의 최종 검증 점수를 토대로 단계적으로 실증할 예정입니다.

FUTURE WORK

한계 및 향후 개선 방향

기하 순환 타깃 탈피, 방향 매핑 교정 및 교통량 데이터 결합 로드맵

1. 기하 순환 타깃 탈피

타깃 정의의 한계 극복

- 현재 타깃(정면 역광 사고 건수)은 기하 정의로 인해 단순 노출시간 규칙이 ML을 상회함
- **개선 과제:** 기하가 정답을 직접 정의하지 않는 **사고 심각도(중상·사망)** 또는 **교통량 대비 전체 사고율** 타깃으로 확장하여 다변량 ML의 실질적 가치 확보

2. 방향 판별 로직 전면 교정

29개 노선 동일 방향 판정 해결

- 사고 좌표 평균치 기반 판별 오류로 인해 29개 노선에서 방위각 역전이 발생함
- **개선 과제:** 노선별 상·하행 공식 기·종점 이정표를 1:1 직결 매핑하는 하드코딩 규칙표로 즉시 개편하여 정면-대조군 분리 무결성 확보

3. 교통량 및 기상 결합

실제 주행 위험 노출 보정

- 구간별 일평균 통행량(VDS/AADT) 미반영으로 인한 실제 차량 노출량 왜곡 보정
- 전국 단일 대표 좌표(36.5°N) 시뮬레이션에서 각 구간 실제 위경도 기반 천문 계산으로 정밀화
- ASOS 기상관측소의 맑음/흐림 일조 시간 결합

개선 일정: 방향 판별 로직 개편 및 단일 피처 기준선과의 비교 분석은 금주 중 즉시 반영하며, 교통량 결합 및 사고 심각도 확장은 최종 발표 단계에서 선보일 예정입니다.

CONCLUSION

결론 및 요약: 엄밀한 데이터 구축과 정직한 머신러닝 평가

과장 없는 성과 공표와 학술적 방어력을 갖춘 고속도로 노출 스크리닝 시스템

🎯 중간 성과 및 주요 기여점

- **표준 데이터셋 구축:** 전국 61개 고속국도 5,782개 구간의 선형·터널·천문 노출 지표를 결합한 1km 단위 표준 데이터베이스 완비
- **공간 검증 체계 확립:** 노선 단위 5-Fold GroupKFold를 설계하여 공간적 데이터 누수 없이 신뢰할 수 있는 외부 일반화 성능 평가 수행
- **실증 검증 완료:** 타깃 시각 무작위 셔플 시 오차가 90% 급증(Deviance 0.1299→0.2473)함을 실측하여 시공간 기하 일치 학습을 입증
- **엔지니어링 완성도:** 엄격한 입력 검증 모듈(AccidentPredictor)과 18개 단위 테스트 작성으로 백엔드 서빙 레디 상태 확보

💡 본 연구의 정직한 태도와 학술적 가치

- **인과 과장 배제:** 대조군 분석(p=0.157)을 투명하게 공개하고, 인과 입증이 아닌 '기하학적 공간 스크리닝 모델'로 명확히 한정
- **단일 기하 규칙 우위의 정직한 보고:** 타깃 기하 결속으로 인해 단순 규칙(24.2%)이 다변량 ML(16.2%)을 상회함을 밝히고, 그 원인을 객관적으로 분석
- **머신러닝의 바른 방향 제시:** 기하가 정답을 결정하는 단순 카운트 타깃에서 벗어나, 교통량 보정 사고율과 사고 심각도 예측으로 ML의 활용 가치를 확장하는 로드맵 정립

5,782개	24.2%	0.1280	100%
스크리닝 대상 구간	단일 기하 지표 포착률 (상위 10%)	단일 피처 Poisson 최저 Deviance	단위 테스트 통과율