SUNSIGHT · 1팀 태양 역광 사고 예측 · 중간 보고

햇빛을 마주보고 달릴 때, 고속도로의 위험 구간은 어디인가?

전국 61개 노선 5,782개 구간 단위 태양광 노출 지표 기반 역광 사고 위험 예측 (모델 ①)

일자: 2026-11-03 **발표**: 박범수 (1팀 / AI Engineer) **대상**: 팀 「눈치」 및 머신러닝 프로젝트 심사단

기 · 문제 정의

연구 배경 및 예측 문제의 엄밀한 정의

인과적 위험 단정이 아닌, 도로 기하구조 기반의 역광 취약 후보 구간 선별 문제로 정식화

🌞 주행 환경의 시각적 위협 (정면 저각도 역광)

- **일출·일몰 시간대(고도 0~25°)**: 태양이 전방 시야 정면에 위치하여 강한 직사광선 유입.
- **차광막(선바이저)의 한계**: 정면 저각도에서는 차광판을 내려도 도로 인지가 제한됨.
- **시야 대비 감소**: 강한 배경광으로 인해 전방 차선 및 선행 차량 윤곽 식별 지연.

🎯 연구 목표의 엄밀한 정의 (인과 ➔ 공간 스크리닝)

- **인과 관계 증명이 아님**: "태양광이 사고를 직접 유발한다"는 인과성을 확정한 것이 아님.
- **연구 목표**: 과거 3년간 집계된 정면 역광 사고 건수를 기반으로, 도로 기하구조와 태양광 노출 지표를 활용해 **"구간별 정면 역광 사고 발생 기댓값(λ)을 추정"**함.
- **역할**: 지형·선형상 태양 역광에 노출되기 쉬운 취약 후보 구간을 사전 선별하는 공간적 스크리닝 모델.

⚖️ **사전 대조군 검정 결과 (객관적 보고)**: 3개년 저각도 태양 조건 사고 220건 중 **정면 태양은 99건(45.0%)**, **등 뒤 태양은 121건(55.0%)**으로 집계되었으며, 양측 정확 이항 검정(H0: p=0.5) 결과 **p=0.157로 통계적으로 유의한 차이가 확인되지 않았습니다**. 따라서 본 모델은 '역광의 사고 증가 효과 증명'이 아니라, **'노출 기하에 따른 구간별 상대적 위험 기댓값 선별(Screening)'**에 초점을 맞춥니다.

기 · 시스템 아키텍처

데이터 구축부터 실시간 추론 모듈까지의 파이프라인

전국 고속도로 공간 인덱싱, 천문 시뮬레이션, 머신러닝 모델링, 프로덕션 서빙 패키지 완성

① 공간 데이터 구축

전국 61개 고속도로
58,846개 정점 결합

5,782개

1km 단위 표준 구간 생성

② 천문 궤적 계산

2024년 윤년 366일
15분 간격 궤적 계산

35,136회

연간·출퇴근 노출 지표 도출

③ 노선 공간 검증

노선 단위 분할로
공간 누수 원천 차단

5-Fold

Poisson LightGBM 학습

④ 프로덕션 서빙

동적 피처 연산 &
엄격한 입력값 유효성 검증

14 Tests

pytest 단위 테스트 통과

📦 최종 배포 패키지 아키텍처 (`src/nunchi_ml/accident`)

- **`solar.py` & `bearing.py`**: 구면 방위각 및 `pvlib` 태양 위치 연산 모듈
- **`build_segments.py`**: 도로 중심선 + 터널 1,327개 + 연간 태양 궤적 결합 5,782개 구간 생성기
- **`predict.py` (`AccidentRiskPredictor`)**: 단일 LightGBM(GBDT) 기반 실시간 위험도 및 등급 추론 모듈

승 · 데이터 전처리

공공데이터 원천 수집 및 무결성 정제

사고 전산망, 도로 중심선 이정좌표, 국가 방재 터널 데이터의 정밀 통합

데이터 종류	원천 기관	수집 규모	전처리 및 결측치 처리 내역	모델 활용처
고속도로 사고	한국도로공사 전산망	4,458건 (2023~2025년)	발생 이정 기반 1km 매핑 완료 (4,454건 성공, 99.9% 결측 0건 확인)	타깃 산출 (`glare_front_count`)
도로 중심선	한국도로공사 이정좌표	58,846개 연속 정점	노선명 누락 1,313건(141·202번 도로) dropna 정제 (57,533건 정상 사용)	1km 구간 분할, 도로 방위각·곡률 산출
도로 터널	국토교통부 표준데이터	3,840개 터널	고속국도 관리 터널 1,327개 필터링 및 시·종점 GPS 좌표 결합	터널 최단거리, 1km 내 터널 유무·포털 수

🔍 결측치 1,313건의 원인 분석 및 정제

공공데이터 원본에서 141번(737개) 및 202번(576개) 노선의 한글 도로명이 원천 누락되어 배포됨을 확인. 매핑 오류를 방지하기 위해 `dropna(subset=['도로명'])`으로 엄격 정제함.

🧭 방향 판별 매핑 검증 완료 (Sanity Check)

동향 도로(45~135°) 정면사고 40건은 **100% 아침(05~09시)**에, 서향 도로(225~315°) 정면사고 53건은 **100% 늦은 오후(14~19시)**에 발생함을 전수 확인하여 방위각 매핑 무결성을 검증함.

승 · 공간 데이터셋

전국 61개 노선, 5,782개 단위 구간 데이터셋 (①-v1)

100m 정점 집계를 통한 1km 공간 격자화 및 31개 분석 피처 체계 구축

🗺️ 공간 격자 인덱싱

- 노선별 기점(0.0km) 기준 1.0km 단위 floor 인덱싱
- **고유 매핑 키**: `route` + `segment_km`
- 0.8km 미만 말단 잔여 구간 52개는 `is_partial_segment` 플래그 부여

📐 기하구조 피처 집계

- **도로 진행 방위각**: 순방향(Forward Azimuth)
- **동서 정렬도**: `ew_alignment`
- **도로 곡률**: 1km 내 정점 간 곡률 평균/최대
- **터널 인접성**: 1km 내 최단 터널 거리

🎯 타깃 분포의 특성

- 3개년 전체 사고 4,454건 중 **정면 저각도 역광 사고 99건**
- 사고 미발생 구간: 5,684개 (98.3%)
- 1건 발생: 97개 구간 / 2건 발생: 1개 구간
- ➔ 극심한 0 팽창(Zero-inflated) 희소 데이터

📊 구축 데이터셋 종합 지표 요약

전국 고속도로 노선	1km 분석 단위 구간	구축 분석 피처	3개년 정면 역광 사고
61개	**5,782개**	**31개 컬럼**	**99건**

승 · 특징 공학

천문 계산 기반 태양광 잠재 노출 지표 설계

실시간 기상 관측이 아닌, 천문 궤적 계산(pvlib)을 통한 물리적 노출 가능 시간 추정치

⚙️ **지표의 명확한 정의**: 본 지표는 운전자의 실제 눈부심 경험 시간이나 기상 관측치가 아니며, **도로의 진행 방위각과 태양의 고도·방위각 기하 조건을 결합하여 산출한 '정면 저각도 태양광 노출 가능 시간의 천문학적 추정치'**입니다.

🌞 정면 저각도 판정 조건 (Geometry)

- **태양 고도 조건**: 0° < solar_elevation <= 25° (지평선 부근 저각도)
- **상대 방위각 조건**: |solar_azimuth − road_bearing| <= 25°
- **등 뒤 태양 판정**: 상대 방위각 155° ~ 180° (대조군 121건)

🔄 2024년 연간 태양 궤적 시뮬레이션

- 대한민국 중심 대표 좌표(36.5°N, 127.8°E) 기준 윤년 366일 계산
- 15분 간격 총 **35,136회** 태양 위치(고도·방위각) 시뮬레이션
- 구간별 도로 방위각과 교차 매칭하여 노출 시간(시간 단위) 도출

annual_glare_hours_fwd

연간 정면 저각도 잠재 노출 추정 시간 (평균 130.6시간, 최대 461.8시간)

commute_glare_hours

출퇴근 집중 시간대(07~09시, 17~19시) 잠재 노출 추정 시간 (평균 158.4시간)

ew_alignment

일출·몰 축과 일치하는 동서 방향성 정렬도 (|sin(bearing)|, 0~1)

공간적 데이터 누수(Data Leakage) 차단 검증 설계

무작위 K-Fold의 한계를 극복하는 노선 단위 5-Fold GroupKFold 프로토콜

❌ 무작위 K-Fold(Random Split)의 왜곡

고속도로 1km 인접 구간들은 지형, 곡률, 터널 배치가 거의 동일합니다. 무작위로 데이터를 나누면 10km 구간으로 11km 구간을 맞히는 **공간적 정보 누출(Data Leakage)**이 발생하여 일반화 성능이 비정상적으로 과대평가됩니다.

⭕ 노선 단위 5-Fold GroupKFold (채택)

전국 61개 노선을 5개 그룹으로 나누어, **동일 노선의 모든 구간은 오직 하나의 검증 폴드에만 속하도록 엄격히 격리**했습니다. 학습에 포함되지 않은 미지의 노선에 배포되었을 때의 일반화 성능을 평가합니다.

📐 폴드별 분할 구성 및 평가지표

- **노선 단위 분할**: 61개 노선의 독립성을 유지하면서, 5개 폴드가 각각 전체 구간의 약 20.0%(약 1,157개 구간)를 차지하도록 균등 분할 지향.
- **평가 지표**: 건수 데이터의 희소성을 반영하는 **Poisson Deviance** 및 예측 상위 10% 구간에서의 **실제 사고 포착률(Capture Rate)**을 주 지표로 채택.

전 · 모델 실험

기준선 모델부터 머신러닝까지 전수 비교

동일 5-Fold GroupKFold 교차검증 환경에서의 엄밀한 성능 대조

모델 구성	피처 투입 조건	Poisson Deviance (↓)	전체 MAE (↓)	상위 10% 포착률 (↑)	결과 평가 및 특성
기준선 0	구간길이 비례 평균	0.1433 (±0.0384)	0.0337	7.1% (7/99건, CI 2.9~14.0%)	특징 없이 전체 평균률로 예측하는 무작위 기준선
단일 피처	연간 노출 시간 순위	-	-	24.2% (24/99건, CI 16.0~34.1%)	기하학적 정의 자체에 의한 단순 노출량 순위 기준선
기준선 1	Poisson GLM (도로·터널만)	0.1434 (±0.0385)	0.0337	4.0% (4/99건, CI 1.1~10.0%)	태양 변수 미투입 시 선형 모델의 한계
실험 1-A	Poisson GLM (+태양 노출)	0.1421 (±0.0382)	0.0337	14.1% (14/99건, CI 8.0~22.6%)	태양 노출 변수 결합으로 포착 건수 증가 (14건)
실험 1-B	LightGBM (도로·터널만)	0.1439 (±0.0379)	0.0333	6.1% (6/99건, CI 2.3~12.8%)	태양 변수 없이는 비선형 트리 모델도 효과 없음
실험 1-C	**LightGBM 기본 (+태양 노출)**	**0.1312 (±0.0377)**	**0.0335**	**12.1% (12/99건, CI 6.4~20.2%)**	**Deviance 감소(0.1433 ➔ 0.1312) 확인**

📈 **비교 분석 요약**: 도로 기하구조에 태양 노출 변수를 추가한 LightGBM에서 동일한 교차검증 조건 대비 Poisson Deviance가 감소(0.1433 ➔ 0.1312)하여 예측 성능 개선을 확인했습니다.

전 · 모델 튜닝

하이퍼파라미터 튜닝 및 성능 분석

교호작용 피처 추가 및 24개 그리드 조합 탐색 결과의 객관적 보고

⚙️ 하이퍼파라미터 탐색 공간 (24조합)

- max_depth: [3, 4, 6] / num_leaves: [7, 15, 31]
- min_child_samples: [30, 50] / 정규화 강도 조절
- **최적 파라미터:** max_depth=3, num_leaves=7, min_child_samples=50, reg_alpha=1.0, reg_lambda=5.0
- ➔ 과적합을 방지하는 얕은 트리 구조와 규제 강화

🔍 튜닝 및 피처 효과의 객관적 분석

- **Deviance 개선폭:** 0.1312 ➔ 0.1299 (-0.0013)
- 교호작용 피처(tunnel_glare_interaction)와 규제 튜닝을 동시 적용한 복합 효과임.
- 동일 5-Fold 내 24개 조합 탐색 결과이므로 외부 독립 데이터에서는 차이가 더 작을 수 있음을 인지함.

📊 기본 모델 vs 최종 모델 비교

구분	Poisson Deviance	전체 MAE	상위 10% 위험구간 포착률	95% exact binomial CI	비고
기본 LightGBM (1-C)	0.1312 (±0.0377)	0.0335	12.1% (12/99건)	6.4% ~ 20.2%	디폴트 파라미터
최종 LightGBM (1-E)	**0.1299 (±0.0379)**	**0.0335**	**16.2% (16/99건)**	**9.5% ~ 24.9%**	**교호작용 추가 + 규제 튜닝**

전 · 의사결정

성능과 구현 복잡도를 고려한 최종 모델 선정

실서비스 엔지니어링 실용성과 해석 투명성을 위한 단일 LightGBM 확정

🔬 앙상블 모델과의 최종 검증 대조

비교 모델	Poisson Deviance	전체 MAE	상위 10% 포착률	평가 및 결정
단일 튜닝 LightGBM (GBDT)	**0.1299 (±0.0379)**	**0.0335**	**16.2%**	**최종 모델 선정 (단순성, 속도, 해석력)**
앙상블 A (LGBM + RF)	0.1306 (±0.0377)	0.0335	16.2%	단일 모델 대비 성능 개선 없음
앙상블 B (LGBM + RF + GLM)	0.1296 (±0.0384)	0.0336	16.2%	Deviance 미세 이득(-0.0003), MAE 악화

① 성능 격차의 미미함

앙상블 B가 수치상 0.1296으로 최저이나 단일 모델과 -0.0003 차이에 불과하며, MAE는 오히려 소폭 악화됨.

② 실시간 서빙 레이턴시

3개 라이브러리를 동시 로드하는 앙상블 대신, 1개 단일 joblib 아티팩트 (`model1-v1.joblib`)로 메모리 절감 및 초고속 추론 달성.

③ 명확한 트리 해석력

단일 LightGBM(GBDT) 모델의 피처 중요도와 개별 트리의 분할 구조를 활용하여 위험 예측 기여 변수와 경로를 명확히 추적 가능.

LightGBM Gain 기반 피처 기여도 분석

인과적 원인이 아닌, 모델 분할 결정에 기여한 상대적 중요도의 통계적 해석

순위	피처명	Gain 비중	물리적 지표 의미
1위	`annual_glare_hours_fwd`	**59.8%**	**연간 정면 저각도 잠재 노출 추정 시간량**
2위	`ew_alignment`	17.5%	일출·일몰 궤적과 일치하는 동서 선형도
3위	`min_tunnel_dist_km`	6.3%	터널 출구부 인접성 (암순응 영향권)
4위	`curvature_mean`	5.0%	1km 구간 내 도로 굴곡도 평균
5위	`curvature_max`	4.7%	1km 구간 내 도로 급커브 최대 굴곡도
6위	`tunnel_glare_interaction`	2.6%	터널 유무 × 출퇴근 노출 복합 교호작용

💡 중요도 해석의 통계적 타당성

- **지배적 기하 변수 (1위+2위 = 77.3%)**: 타깃(정면 역광 사고)과 피처가 모두 도로 방위각 기하와 연결되어 있어 노출 추정 시간과 동서 선형도가 가장 큰 분할 기여를 보임.
- **터널과의 복합 효과 (3위+6위 = 8.9%)**: 터널 출구부와 출퇴근 시간대 노출의 복합 상호작용이 예측 성능 개선에 기여한 것으로 해석 가능.
- **해석상 주의점**: 위 중요도는 사고의 직접적 '원인성'을 뜻하는 인과율이 아니라, **"트리 모델이 손실함수를 줄이는 데 기여한 상대적 분할 중요도(Gain)"**임.

결 · 엔지니어링 구현

위험 등급 체계 및 추론 모듈 구현

운영상 임계값에 기반한 3분할 등급화와 실서비스 추론 API 완성

일반 후보 **일반 구간**

예측 기댓값 < 0.025

4,096개

전체 고속도로의 **70.8%**

관심 후보 **주의 구간**

예측 기댓값 0.025 ~ 0.035 (평균의 약 1.5배)

1,282개

전체 고속도로의 **22.2%**

우선 점검 후보 **고위험 구간**

예측 기댓값 >= 0.035 (평균의 약 2.0배)

404개

전체 고속도로의 **7.0%**

📌 **등급 임계값 정의**: 전체 구간 평균 예측 기댓값(λ ≈ 0.017)을 기준으로 상대적 위험을 구분하기 위한 운영상 임계값(약 1.5배, 2.0배)이며, 통계적 최적 경계값이나 사고 확률 자체를 의미하는 것은 아닙니다.

🛠️ 프로덕션 추론 클래스: `AccidentRiskPredictor` (`predict.py`)

- **동적 파생 피처 자동 연산**: 기본 11개 피처 입력 시 `tunnel_glare_interaction` 피처 자동 생성.
- **엄격한 유효성 검증(Validation)**: 필수 피처 누락, 문자열, `NaN`/`inf` 유입 시 즉시 `ValueError` 발생 (암묵적 0 대체 차단).
- **단위 테스트**: `tests/test_accident.py` 14개 테스트 전수 통과.

결 · 시스템 연계

모델 ②·③과의 개념적 연계 방안 검토

단독 모델을 넘어, SunSight 서비스 전체 파이프라인의 핵심 공간 축 역할

🕶️ 모델 ② (차량 영상 기반 눈부심) 연계 검토

- **기하학적 조건 공유**: 모델 ①의 정면 저각도 역광 조건(고도 0~25°, 방위각 오차 ±25°)이 모델 ②의 시선-태양 각도 지표 G의 이론적 기초로 기능함.
- **상호 보완**: 실시간 카메라 영상 모델에 지형·선형 기반의 태양 위치 계산 모듈을 보조 신호로 결합하는 방안 검토.

🚇 모델 ③ (터널 순응) 연계 검토

- **구간 사고율 테이블 제공 완료**: 전국 5,782개 구간의 평소 사고율과 역광 예측값이 담긴 `segment_accident_rates_v1.csv` 전달.
- **통합 위험 평가 설계 검토**: 모델 ①의 구간별 사고 발생 기댓값(λ)을 공간적 기초 위험 지표로 활용하고, 모델 ③의 터널 순응 점수를 추가 변수로 결합하는 프레임워크 설계 가능성 논의 중.

🤝 **역할 분담**: 출퇴근 전체 경로 중 **"일반 고속도로 구간"**은 모델 ①(역광 노출 취약도)이 담당하고, **"터널 입출구 구간"**은 모델 ③(순응 부담)이 담당하여 종합적인 출퇴근 안전 정보를 제공할 수 있습니다.

결 · 한계 및 과제

검증된 성과와 기술적 한계의 분리

현재 모델 ①이 가진 제약 사항과 최종 보고서를 위한 개선 방향

⚠️ 교통량(VDS) 미반영

한계: 구간별 통행량(AADT)이 통제되지 않아, 수도권 다교통량 노선의 기본 사고 건수 편차가 모델에 내재됨.
개선: 한국도로공사 VDS 교통량 데이터 확보 후 위험 노출 인원(Exposure) 변수로 보정.

⚠️ 대표 좌표 천문 시뮬레이션

한계: 전국 대표 좌표의 태양 궤적을 일괄 적용하여 지역별 실제 태양 고도·방위각 차이를 완전히 반영하지 못함.
개선: 5,782개 구간별 실제 위경도 기준 개별 태양 궤적 완전 개별화 연산.

⚠️ 실시간 기상 결합 부재

한계: 천문 계산상 정면 역광 조건이어도 흐린 날이나 비 오는 날에는 실제 눈부심이 발생하지 않음.
개선: 기상청 ASOS 실시간 운량·일조 데이터와의 동적 온디맨드 필터링 구축.

📝 **향후 추가 점검 과제**: 사고 발생 시각을 무작위로 치환하는 **셔플(Shuffle) 검증**을 수행하여 성능 개선이 기하학적 정의에서 기인한 것인지 추가 확인하고, 대조군(등 뒤 사고)과의 비교 분석을 정밀화할 계획입니다.

결 · 총평 및 일정

1팀 중간 결과 총평 및 향후 마일스톤

데이터 구축과 모델링 검증 완료, 이제 통합 시스템 실증으로

🏆 1팀 핵심 성과 요약

- **데이터 구축 완료**: 전국 61개 노선 5,782개 구간 및 31개 피처 완비.
- **공간 검증 완결**: 노선 단위 5-Fold GroupKFold 검증으로 예측 오차 감소 확인.
- **엔지니어링 완료**: 실서비스 배포용 단일 LightGBM(GBDT) 및 추론 모듈 구현, 단위 테스트 14개 통과.
- **협업 기여**: 모델 ②·③과의 연계 데이터(`segment_accident_rates_v1.csv`) 납품 완료.

🗓️ 최종 발표까지의 로드맵

- **11/03 (오늘 18:00)**: 노션 데이터 명세서(ML-39) 최종 제출 완료
- **11/04 ~ 11/06**: 모델 ③ 출퇴근 경로 결합 및 전체 위험 지도 실증
- **11/09 (월 18:00)**: 🚨 최종 보고서 및 발표 PPT 제출
- **11/10 (화 16:00)**: 🎤 최종 발표 평가

🚀 **1팀의 약속**: 단단하게 구축된 공간 모델 ①을 바탕으로, 팀 「눈치」의 SunSight 서비스가 실제 도로 안전에 기여할 수 있도록 끝까지 완결성 있게 추진하겠습니다. 감사합니다.