3조(눈치) 데이터 명세서

머신러닝 기반 도로 환경별 태양 눈부심 위험 모니터링 및 시각 증거 분석 시스템 (SunSight)

팀명 / 프로젝트	작성 및 담당	문서 버전	제출 일시
팀 「눈치」 (Nunchi-ML)	**박범수(①) · 이성진(②) · 최재혁·권수영(③)**	**v1.0 (노션 v0.12·모델링 v1.5 정본)**	**2026-11-03 (화) 18:00**

1. 프로젝트 데이터 아키텍처 및 수집 개요

본 문서는 SunSight 시스템의 3대 핵심 머신러닝 서브모델(**모델 ① 도로 기하·태양 노출 사고 예측, 모델 ② 주행 영상 눈부심 정도 분류, 모델 ③ 터널 진·출입 순응 부담 사고 분석**)을 구축하기 위해 수집·정제·통합한 원천 데이터, 변수 사전, 데이터 품질 현황 및 파생변수 생성 규약을 정의합니다.

🗺️ 모델 ① 사고 위험 예측 & Layer 1

- **원천**: 고속도로 사고(4,458건), 도로중심선(58,846점), 터널(1,327개)
- **분석단위**: 전국 61개 노선 **5,782개 1km 구간** (①-v1) & 대구 달구벌대로 **164개 200m 링크**
- **타깃**: 정면 저각도 역광 사고 건수 (99건, Poisson 회귀)

👓 모델 ② 눈부심 정도 분류 & G 모델

- **원천**: GLARE(2,157장), 대구/서울 Mapillary(344장), AI Hub 역광(308장), ASOS 기상
- **특징**: 화면 픽셀 12종 + G 후보 7종(화각 반영 6종 / 운전자 기준 4종)
- **타깃**: 0 정상 / 1 눈부심 / 2 심한 눈부심 (3단계 분류)

🚇 모델 ③ 터널 순응 부담 분석

- **원천**: 고속도로 사고(4,443건), OSM 도로망(11,749개), 터널(1,327개), ASOS 일사(49곳)
- **분석단위**: 사고 4,443 + 같은 자리 평소 15,017 = **19,460행** (③-v1)
- **타깃**: 사고 1 / 평소 0 (조건부 로지스틱)

2. 공통 데이터 파이프라인 및 거버넌스 규칙

2.1 천문 기하학적 태양 위치 계산 규약 (공통 엔진)

항목	명세 내용	수학적 정의 및 적용 기준
천문 계산 라이브러리	`pvlib.solarposition.get_solarposition`	NREL SPA(Solar Position Algorithm) 기반 정밀 천문 궤적 산출
투입 및 산출 변수	투입: 일시(KST), 위도(lat), 경도(lon) 산출: 태양 고도각(θ_{alt}), 태양 방위각(φ_{sun})	$\theta_{alt} \in [-90°, 90°]$ (수평선=0°), $\varphi_{sun} \in [0°, 360°)$ (정북=0°, 시계방향)
정면 저각도 눈부심 조건	고도 $0° < \theta_{alt} \le 25°$ 및 방위각 차이 $\Delta\varphi \le 25°$	원형 거리: $\Delta\varphi_i(t) = \min(\lvert\varphi_{sun}(t) - \varphi_i\rvert, 360° - \lvert\varphi_{sun}(t) - \varphi_i\rvert) \le 25°$ (민감도: ±20°, ±30°)

2.2 미래 데이터 누수(Data Leakage) 의심 변수 통제 및 결정

🚨 **데이터 누수 원천 차단 원칙**: 타깃(사고 또는 눈부심 라벨)이 정해진 **이후에** 기록되거나 예측 시점 미래의 정보를 담은 변수는 모델 입력에서 철저히 배제합니다.

대상 모델	의심 변수명	데이터 누수(Leakage) 의심 사유	팀 최종 처리 결정	결정자 · 일자
모델 ①	`사고원인`, `사망`, `부상`	사고가 발생한 뒤 사후 조사 과정에서 기록되는 결과 변수임	**입력 전면 제외** (사후 검증·대조용으로만 집계)	박범수 2026-11-02
모델 ②	ASOS `일조(ss)`, `일사(icsr)`	촬영 시각의 가장 가까운 정시 값을 붙일 경우, 촬영 뒤 최대 30분간의 미래 기상 누적치가 혼입될 수 있음	**조건부 사용** (앱·BE 실시간 추론 시 **직전 정시 값만** 사용)	이성진 2026-11-03
모델 ③	`사고원인`	사고 발생 후 기록되는 사후 판정 값임	**입력 전면 제외**	최재혁 2026-11-02

2.3 데이터셋 버전 및 모델별 데이터 분할·평가 및 추정 규칙

항목	모델별 데이터 분할·평가 및 추정 규칙
버전 명명 규칙	데이터셋 이름은 **[모델 번호]-[버전]**으로 표기 (`①-v1` , `②-v1~v3` , `③-v1`). 버전이 다른 데이터셋끼리는 점수를 비교하지 않음.
분할·평가·추정 (모델별 구분)	예측 모델(①·②)은 동일 노선·동일 촬영 묶음 누수 차단을 위해 **GroupKFold 5겹 분할**을 기본 원칙으로 함: **[모델 ①]** 61개 고속도로 노선 기준 5-Fold CV (`seed=0` 고정) / **[모델 ②]** 시범·기본 평가는 촬영 묶음 5-Fold(`seed=0`), 소규모 촬영 묶음(24개)인 `②-v3(G)` 는 분할 편차 완화를 위해 **촬영 단위 5-Fold × 30회 반복(`seed=0..29`)** 및 **카메라 홀드아웃(LOCO)** 병행 / **[모델 ③]** 사건 층(`case_id` : 사고 1건+동일 지점·요일·시각 대조군 3~4건) 매칭 설계 및 조건부 로지스틱 회귀 추정.

3. 모델 ①: 고속도로 사고 위험 예측 & 도심 Layer 1 잠재 노출

3.1 기본 데이터셋 구성 정보

데이터 구분	로컬 파일 경로 (`data/`)	규모 (행 × 열)	수집 기간	출처
고속도로 교통사고	`expressway/`한국도로공사_사고이정별좌표및기상`_2023-2025.csv`	4,458 × 13 (결측 0)	2023.01 ~ 2025.12	공공데이터포털 (15164206)
도로중심선 이정 좌표	`expressway/`한국도로공사_도로중심선_이정좌표`.csv`	58,846 × 7 (정제 57,533)	2025년 기준	고속도로 공공데이터 포털
전국 도로터널 표준데이터	`tunnel/`국토교통부_전국도로터널정보표준데이터`.csv`	3,840 × 33 (고속 1,327)	2025.12 기준	공공데이터포털 (15081955)
최종 분석셋 (①-v1)	`expressway/segment_1km_dataset_v1.csv` · `folds_model1_v1.csv`	**5,782 × 31** (12피처)	2023~2025 집계	자체 구축 (61노선 5-Fold)
도심 확장 (dalgu-v2)	`dalgu_solar_exposure_v2.json` (AI) · `src/data/dalgu.json` (FE)	**164개 링크** (32.81km)	2024 윤년 35,136시점	대구 달구벌대로 OSM 중심선

3.2 모델 ① 원본 변수 사전 및 품질 처리 (12종)

원천	변수명	변수 설명	타입	범위 · 분포값	결측	전처리 및 활용
사고	사고일자 · 사고시간	사고 발생 일시 (분 단위)	시각	2023-01-01 ~ 2025-12-31	0건	datetime 결합 · 태양 위치 계산
사고	사고노선	고속도로 세부 노선명	범주형	61개 고속도로 노선	0건	GroupKFold 노선 분할 기준 키
사고	사고발생이정	노선 기점 기준 위치 (km)	연속형	0.0 ~ 420.0 km	0건	floor(이정)으로 1km 구간 매핑
사고	사망 · 부상	인명 피해 인원수	연속형	사망 0~3, 부상 0~25	0건	검증 참조 (모델 입력 제외)
사고	날씨(기상상태)	사고 당시 기상 상태	범주형	맑음(3,365건), 흐림, 비 등	0건	맑은 날 정면 역광 사고 대조용
사고	X좌표 · Y좌표	사고 발생 지점 위·경도	연속형	북위 34.8~38.1°, 동경 126.3~129.4°	0건	개별 사고 실제 좌표 pvlib 투입
도로중심선	도로명	중심선 소속 노선명	범주형	61개 노선	**1,313건**	**dropna 제거** (57,533건 확보)
도로중심선	이정	100m 간격 도로 이정	연속형	100m 단위 연속 값	0건	1km 구간 분할 및 선형 집계
도로중심선	X좌표값 · Y좌표값	중심선 정점 위·경도	연속형	전국 고속도로 정점	0건	인접 정점 간 방위각·곡률 산출
도로터널	도로종류	도로 행정 등급 분류	범주형	고속국도, 일반국도 등	0건	고속국도 (1,327개)만 필터링
도로터널	터널연장	터널 총 길이 (m)	연속형	50 ~ 10,965 m	0건	1km 내 최대 연장 집계 피처화
도로터널	터널시점/종점 좌표	터널 입·출구 위·경도	연속형	전국 터널 위치 좌표	0건	최근접 터널 거리 및 포털 수 집계

3.3 모델 ① 파생변수 명세 및 검증 효과

파생변수명	산출 수식 및 생성 방법	설계 의도	중요도(Gain) 및 성능 기여 효과
`annual_glare_hours_fwd`	2024년(윤년 366일, 35,136시점) 15분 간격 시뮬레이션 중 $\theta_{alt} \in (0°, 25°]$ 및 순방향 $\Delta\varphi \le 25°$ 누적 시간(h)	구간별 연간 정면 저각도 태양 노출 총 위험량 반영	**LightGBM Gain 59.8% (1위)** Deviance 0.1439 → 0.1312 (-8.5%), 상위 10% 포착률 2배 상승
`ew_alignment`	`|sin(radians(bearing_fwd))|` (0=남북, 1=동서축 완전 일치)	일출·일몰 태양 궤적에 취약한 동서축 도로 정렬도 정량화	**LightGBM Gain 17.5% (2위)** 주요 도로 기하 특성 반영
`curvature_mean` · `max`	1km 구간 내 100m 정점 간 방위각 변화량 평균 및 최댓값 (°)	급커브 등 도로 기하구조의 물리적 사고 위험 통제	**합산 Gain 9.7% (4·5위)** 평균 5.0%, 최대 4.7%
`tunnel_glare_interaction`	`has_tunnel_within_1km * commute_glare_hours` (동적 생성)	터널 출구 직후 강한 직사광 노출 시 순응 지연 복합 위험 반영	**LightGBM Gain 2.6% (6위)** 최종 Deviance 0.1299, 상위 10% 포착률 16.2% 달성
`commute_glare_hours`	출퇴근 시간대(07~09시, 17~19시) 중 정면 저각도 역광 누적 시간(h)	교통량 집중 피크 시간대 시각 장애 노출 가중	**LightGBM Gain 2.1% (7위)** 시간대별 노출 위험 세분화
[도심 Layer 1] `dalgu_exposure_v2`	달구벌대로 164개 링크 주행방향 분리 (Eastbound/Westbound) 청천 잠재 노출시간 및 평균 대비 상대 배율(`risk_mult`)	도심 200m 구간 외삽 왜곡 배제 및 물리적 사전 스크리닝	출근 동향 최대 **423.0h (57.8%)**, 퇴근 서향 **443.0h (60.5%)**, Tier 유지율 **91.5%**, 순열검정 $p_{MC} \approx 0.0001$

4. 모델 ②: 주행 영상 기반 눈부심 정도 분류 및 G 모델

4.1 원천 데이터셋 및 버전 구축 현황

데이터셋 / 버전	파일 위치 (`data/`)	장수 / 규모	구축 내용 및 평가자 일치도(Kappa)
GLARE 원본	`glare/Images/vidN/*.png`	2,157장 (33영상)	미국 도로 주행 눈부심 공개 벤치마크 (Gray et al., 2023, 937×540, CC BY 4.0)
②-v0 (시범)	`pilot_glare/pilot_labels.csv`	130장	GLARE 영상당 4장 추출 시범 라벨 (정상 47 · 눈부심 56 · 심한 27)
②-v1 (대구)	`glare_mapillary/labels_drive.csv` · `dash.csv`	284장	한국 도로 대구: 운전 시점 124장 2인 독립 라벨(성진·범수, **코헨 카파 0.56, 가중 0.67**) + 블랙박스 160장
②-v2 (AI Hub)	`aihub_special/labels_merged.csv`	304장	AI Hub 특수환경 역광(대전·서울·창원, 1920×1200) 3인 독립 라벨(성진·범수·수영, **플라이스 카파 0.59**, 동률 4장 제외)
②-v3 (G)	`glare_mapillary_seoul/` 외	**320장** (24촬영)	G 학습 정본: 대구 방향 신뢰 260장 + 서울 운전 시점 60장(3인 다수결) + **ASOS 대구·서울 기상 결합**
②-v4 (시험)	`aihub_special/drive_heading.csv`	**624장** (4카메라)	**외부 시험용**: ②-v3 + AI Hub 304장 (방향 복원, ASOS 서울·대전·창원). 미학습 카메라 도메인 시프트 검증용

4.2 입력 변수 정의서: (A) 화면 숫자 12개 & (B) 해 위치·날씨 G 후보 7종 (화각 반영 6종 / 운전자 기준 4종)

구분 · 투입 모드	변수명	산출 방법 및 물리적 설명	타입	분포 범위
(A) 화면 숫자 (12개 비전) `features.py` 640×368	`white_ratio`	하얗게 포화된 픽셀 비율 (Gray 밝기 > 245)	연속형	0.00 ~ 0.14
	`bright_blob`	가우시안 블러(41×41) 후 크게 번진 밝은 덩어리 비율 (> 230)	연속형	0.001 ~ 0.17
	`mean_all` · `sky_mean`	화면 전체 평균 밝기 및 상단 45%(하늘) 평균 밝기	연속형	96~137 / 137~193
	`road_mean` · `contrast`	하단 도로 영역(세로 60~85%, 가로 20~80%) 평균 밝기 및 표준편차(대비)	연속형	49~138 / 23~58
	`sky_road_ratio`	하늘 평균 밝기 / 도로 평균 밝기 비 (역광 대비 강도)	연속형	1.1 ~ 3.1
	`road_sharp`	도로 영역 라플라시안(Laplacian) 분산 (차선·노면 윤곽 선명도)	연속형	300 ~ 2,569
	`low_sat`	HSV 채도(S) < 25 인 픽셀 비율 (빛 번짐으로 색이 빠진 희뿌연 정도)	연속형	0.11 ~ 0.79
	`brightest_x` · `y`	블러 이미지 내 가장 밝은 점의 정규화 가로·세로 위치 (좌상단 원점)	연속형	0.0 ~ 1.0
	`brightest_val`	블러 이미지 내 가장 밝은 점의 휘도 값	연속형	232 ~ 255
(B) 해 위치·날씨 (G 후보 7종) • **화각 반영(6종)**: `sun_alt,u,v,in_fov,cloud,sunshine` • **운전자 기준(4종)**: `sun_alt,gap,cloud,sunshine`	`sun_alt` [공통]	촬영 시각·GPS 기반 태양 고도각 (°)	연속형	0° ~ 90° (낮)
	`gap` (Δ) [운전자 4종]	해 방위각과 차량 진행 방향의 원형 각도 차이 (화각 모를 때 사용, 0° = 정면)	연속형	0° ~ 180°
	`u` · `v` [화각 6종, 2열]	초점거리(화각) 반영 화면 내 해의 정규화 가로(`u`)·세로(`v`) 좌표 (`gap` 투영·대체)	연속형	±1 = 화면 경계
	`in_fov` [화각 6종]	해가 카메라 화면 화각 안에 들어와 있는지 여부 ($\|u\| \le 1 \wedge 0 < v \le 1$)	이진형	0 또는 1
	`cloud` · `sunshine` [공통]	기상청 ASOS 전운량(0~10) 및 직전 1시간 일조 비율 (0.0~1.0)	연속형	0~10 / 0.0~1.0

4.3 데이터 정제 7단계 파이프라인 및 파생변수 효과

파생/정제 항목	생성 및 처리 규칙	품질 개선 및 점수 변화 효과
시각 보정 (2단계)	구형 카메라가 KST를 UTC로 저장한 오류를 썸네일 밝기로 탐지 해 0 · -9 · +9시간 보정	대구 54/73묶음, 서울 303/1,247묶음 시간대 정상 복원
`heading_suspect` (3단계)	GPS 이동 경로 방향과 카메라 방향이 45° 넘게 다르면 표시 후 제외 (거르기용)	신호 대기·서행 중 방향 기록 오류 사진(육안 확인 13장 모두) 완벽 제거
`kmh` (4단계)	묶음 내 GPS·시각으로 이동 속도 중앙값 산출하여 20 km/h 이상만 선별 (거르기용)	인도·보행·기차 창밖 묶음 배제 (서울 정면 53묶음 중 운전 시점 6묶음 선별)
`u` · `v` · `in_fov` (G 피처)	초점거리로 가로·세로 화각을 구해 해의 화면 위치로 변환 (`gap` 대체)	카메라 홀드아웃(LOCO, 눈부심 여부): 손 규칙 평균 0.65 → **화각 반영(6종) 로지스틱 0.81** (광각 0.30 → 0.86)
[최종 확정] `G` 만 (로지스틱)	**모델링 계획서 v1.5 확정**: 화각 반영 G 6종 로지스틱 (미학습 기기 노출 편차 강건성 확보)	외부 카메라(AI Hub) 시험 시 화면 결합 모델(0.45 붕괴) 대비 **물리 G 모델 0.74 안정적 유지**. 알림 기준: P(여부)≥0.5, P(심함)≥0.5

5. 모델 ③: 터널 진입·진출 순응 부담 분석 (Case-Crossover)

5.1 기본 데이터셋 구성 정보

데이터 구분	파일 경로 (`tunnel_adaptation/`)	규모 (행 × 열)	설명 및 출처
고속도로 사고 · 터널	`1_원본/accident.csv` · `tunnel.csv`	4,458 × 13 / 3,840 × 33	모델 ①과 동일 원천 (고속국도 터널 1,327개)
고속도로 선형 (OSM)	`1_원본/south-korea-free.shp.zip`	11,749개 구간 (10,910km)	Geofabrik OSM 고속도로 상·하행 방향별 연결망
시간별 기상 (ASOS)	`1_원본/asos_hourly_all.csv`	95개 관측소 × 1시간	**일사량(icsr) 측정 관측소 49곳**만 선별 사용 (중앙값 거리 16.8km)
최종 분석셋 (③-v1)	`3_결과/train_casecross.csv`	**19,460행** (4,443 + 15,017)	사고 1건당 같은 자리·요일·시각의 다른 주 3~4개 대조군 묶음

5.2 순응 부담 점수 (A) 물리 계산식 및 파생변수 명세

$$(1)\ \text{일사강도}\ I = \text{icsr} \times 277.8\ (\text{W/m}^2) \rightarrow (2)\ \text{외기 조도}\ E_v = I \times 126\ (\text{lx}) \rightarrow (3)\ \text{야외 휘도}\ L_{20} = (0.15 \times E_v) / \pi\ (\text{cd/m}^2)$$

$$(4)\ A_{\text{진입}} = \log_{10}(L_{20} / (280 \times \text{조광단계})) / 2 \quad | \quad A_{\text{진출}} = \log_{10}(L_{20} / 45) / 2 \quad (\text{범위: } 0 \sim 1 \text{ 클리핑})$$

변수명	구분	생성 방법 및 물리·통계적 처리	데이터 품질 정제 및 비고
`icsr` (일사량)	원본 기상	1시간 누적 일사량 (MJ/m², 범위 0 ~ 3.5)	**[중대 버그 수정]** 일사 미측정 26개 관측소의 빈칸이 0으로 들어가 낮 사고 32%가 A=0이 되던 문제를 **일사 측정 49곳 매핑**으로 해결
방향 (차로 매칭)	원본 사고	노선별 `방향규칙표.csv` 를 통해 이정 증가/감소 차로 변환	단순 최근접 매칭 시 반대 차로에 붙던 오류를 **1,903건 → 57건**으로 대폭 축소
`tunnel_zone`	파생 스위치	터널 입·출구 거리 기준 구간 판정 (진입전 150m ~ 내부 100m, 출구전 60m ~ 진출후 150m)	$A_{\text{진입}}$ · $A_{\text{진출}}$을 켜고 끄는 스위치 (국토부 지침 원문 대조 검토 중)
`A_진입` · `A_진출`	핵심 파생	터널 진입(밝음→어둠) 및 진출(어둠→밝음) 시 망막 순응 부담 점수 (0~1)	진입 낮 사고 139묶음에서 A 0.1당 OR **1.25** (95% CI 0.93~1.68): 양(+)의 방향 추정치이나 CI가 1.0을 포함하여 통계적 불확실성 존재
`rn` · `vs` · `is_holiday`	통제 변수	강수량(mm), 시정(m), 공휴일/주말 여부	비 오는 어두운 날의 노면 사고 효과를 분리하여 A의 순수 효과 추정 (1.20 → 1.25)

6. 전사 데이터 품질 관리 요약 및 버전 변경 이력

버전	일자	작성자	핵심 변경 및 데이터 정제 내역
v0.1~v0.4	10-26 ~ 10-30	이성진	변수정의서 + 데이터 파이프라인을 데이터 명세서로 통합, 모델별 섹션 분리, 화면 숫자 12개 및 시범 라벨(`②-v0`) 기록
v0.5~v0.6	2026-11-02	최재혁 · 권수영 · 이성진	모델 ③ 터널 순응 섹션 추가, 누수 변수(사고원인) 제외 확정, AI 공통 패키지 경로(`src/nunchi_ml/`) 반영
v0.7	2026-11-02	박범수	모델 ① 사고 위험 예측 명세 완성 (원본 12종, 도로명 결측 1,313건 제거, 6단계 파이프라인, `①-v1` 5,782구간 및 파생 5종)
v0.8~v0.11	2026-11-03	이성진 · 최재혁 · 권수영	모델 ② 한국 도로·AI Hub·ASOS 및 G 입력 표 추가, 촬영단위 30회 반복 / 모델 ③ 일사량 49개 관측소 버그 수정 및 `③-v1` (19,460행) 실행 결과 반영
v0.12	2026-11-03	이성진	모델 ② AI Hub 방향 복원(3-1단계), `②-v4` 외부 시험셋(624장), ASOS 대전·창원, 카메라 표준화·해자리 밝기 파생, 팀 데이터 번들 안내
v1.0 (정본)	2026-11-03	박범수 (통합)	4일차 제출용 전사 데이터 명세서 통합본 (모델링 계획서 v1.5의 모델 ② 최종 서빙 **G 만** 확정 및 모델 ① 도심 달구벌대로 `dalgu-v2` 동기화)